PIGIER BÉNIN

Master en Intelligence Artificielle et Big data

RAPPORT DE PROJET

Projet Big Data

Enseignant : Dr. BABATOUNDE Moctard Olouladé

Étudiant : DRAMANE Hamzath

Année Académique 2025-2026

Introduction Générale

Dans le cadre du module « Projet Big Data » du Master en Intelligence Artificielle et Big data à PIGIER BÉNIN, deux projets d'analyse de données ont été réalisés. Ces projets illustrent concrètement comment les outils de Data Science peuvent transformer des données brutes en décisions d'affaires.

Le premier projet porte sur l'analyse d'une enquête de marché menée auprès de 123 professionnels de la restauration. L'objectif : guider le lancement d'une activité de vente de plats jetables. Ce projet s'appuie sur la bibliothèque pandas et des techniques de machine learning (K-Means) pour extraire des profils de clients et formuler des recommandations concrètes.

Le second projet confronte à une réalité différente : plus d'un million de transactions commerciales issues du jeu de données retailsale.csv. Pour relever ce défi de volume, Apache Spark — framework de traitement distribué — a été utilisé. Ce projet démontre la nécessité d'adapter les outils au volume des données, et livre des insights sur les dynamiques de ventes d'un réseau de 107 magasins sur 324 produits.

Ce rapport présente, pour chaque projet, la démarche complète : préparation des données, analyse exploratoire, visualisations issues des notebooks, modélisation et recommandations.

Projet 1 — Analyse d'une Enquête de Marché pour la Vente de Plats Jetables

2.1 Contexte et Objectifs

Une entreprise locale envisage de lancer une activité de vente de plats jetables. Plutôt que de se lancer à l'aveugle, une enquête de terrain a été conduite auprès des vendeurs de repas, restaurateurs et traiteurs susceptibles d'être clients. Les résultats ont été fournis sous forme de fichier Excel (enquête.xlsx).

Cette démarche est essentielle : trop d'entreprises lancent des produits sur la base d'intuitions, là où les données permettent d'ancrer les décisions dans la réalité du marché. Les quatre objectifs de l'analyse étaient les suivants :

- Nettoyer et structurer les données d'enquête pour les rendre exploitables.
- Analyser les préférences et comportements des clients potentiels.
- Identifier les facteurs influençant l'intention d'achat.
- Formuler des recommandations stratégiques sur le produit, le prix et l'approvisionnement.

2.2 Description des Données

Le fichier enquête.xlsx contient 123 réponses collectées auprès de professionnels de la vente alimentaire, réparties en 29 variables. Ces données couvrent le profil des répondants, leurs habitudes actuelles d'utilisation d'emballages, leurs préférences produit (taille, compartiments, matériaux) et leur sensibilité au prix.

Catégorie	Variables principales	Description
Identification	Code agent, Date du recensement	Métadonnées de collecte
Profil répondant	Que vendez-vous principalement ?	Type d'activité commerciale
Usage actuel	Utilisation d'emballages, Quantité par jour	Habitudes existantes
Préférences produit	Compartiments, Contenance, Matériaux, Design	Attentes et critères de choix
Sensibilité prix	Budget mensuel, Prix actuel pour 100 plats	Fourchettes envisagées
Intention d'achat	Disposé à payer plus ? Acheteriez-vous ?	Réceptivité à l'offre
Approvisionnement	Fréquence souhaitée, Mode d'approvisionnement	Logistique attendue

Tableau 1 — Vue d'ensemble des 29 variables de l'enquête

2.3 Préparation des Données

La préparation des données est une étape incontournable avant toute analyse. Pour cette enquête, trois opérations principales ont été réalisées :

- Nettoyage des espaces inutiles en début et fin de chaîne de caractères pour toutes les colonnes textuelles.
- Harmonisation en minuscules : uniformiser « Oui », « oui » et « OUI » en une seule valeur évite les erreurs de comptage.
- Traitement des valeurs manquantes : les colonnes textuelles ont été complétées par « non renseigné » — une décision plus honnête que de supprimer les lignes ou d'inventer une valeur.

Résultat : après nettoyage, le fichier ne présente plus aucune valeur manquante sur les 123 enregistrements. Le graphique ci-dessous montre la distribution initiale des valeurs manquantes avant traitement.

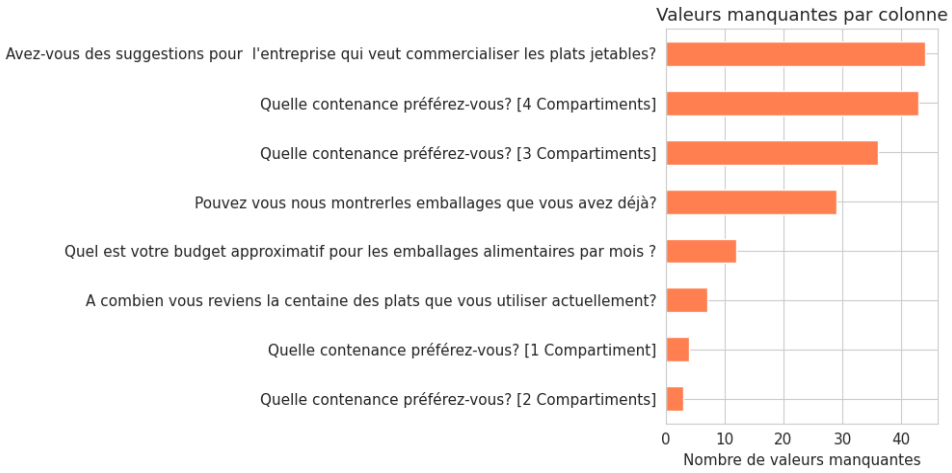

Figure 1 — Valeurs manquantes identifiées avant traitement (par colonne)

> **Observation :** *Les colonnes sur les contenances à 3 et 4 compartiments concentrent la plupart des valeurs manquantes — ce qui est logique : les répondants qui ne souhaitent pas ces formats n'ont pas renseigné ces champs. Ce n'est pas une erreur de collecte, mais un comportement naturel de réponse.*

2.4 Analyse Exploratoire

4.1 Types d'activités des répondants

La première question fondamentale est : à qui avons-nous affaire ? L'analyse du type d'activité principal des répondants révèle une grande diversité dans l'échantillon.

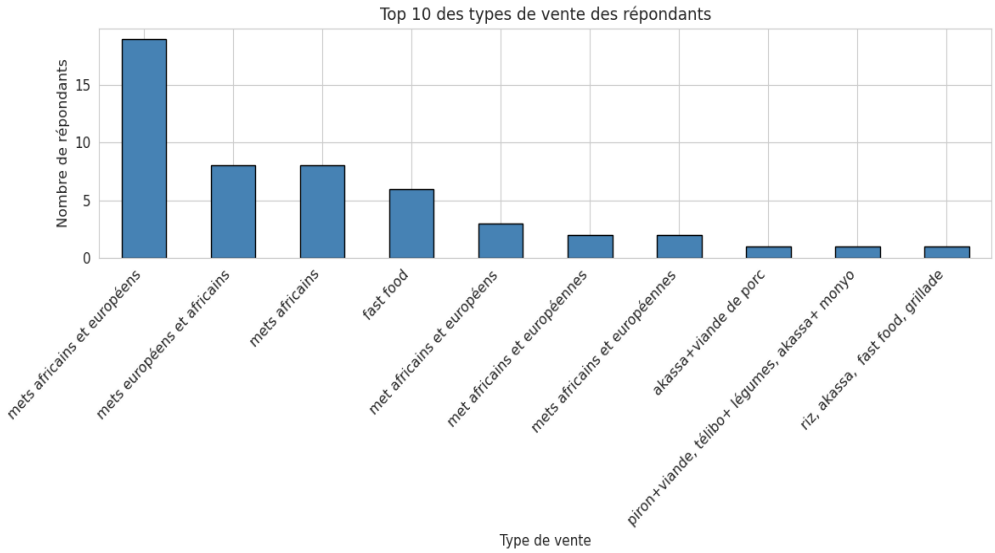

Figure 2 — Top 10 des types d'activité déclarés par les répondants

Observation : *La majorité des répondants sont des vendeurs de « mets africains et européens » (19 répondants, 15,4 %), suivis des vendeurs de mets africains uniquement et des fast-foods. On note une grande diversité des formulations, ce qui explique le travail d'harmonisation réalisé lors du nettoyage. En consolidant les catégories similaires, la restauration africaine et mixte représente la part dominante de notre marché cible.*

4.2 Utilisation actuelle des emballages alimentaires

Un résultat remarquable ressort dès la première analyse : la totalité des 123 répondants (100 %) utilisent déjà des emballages alimentaires jetables dans leur activité. Ce constat change fondamentalement la stratégie de lancement : nous ne cherchons pas à créer un besoin, mais à proposer une meilleure offre à des clients qui ont déjà une pratique établie.

La question suivante porte sur les quantités utilisées quotidiennement :

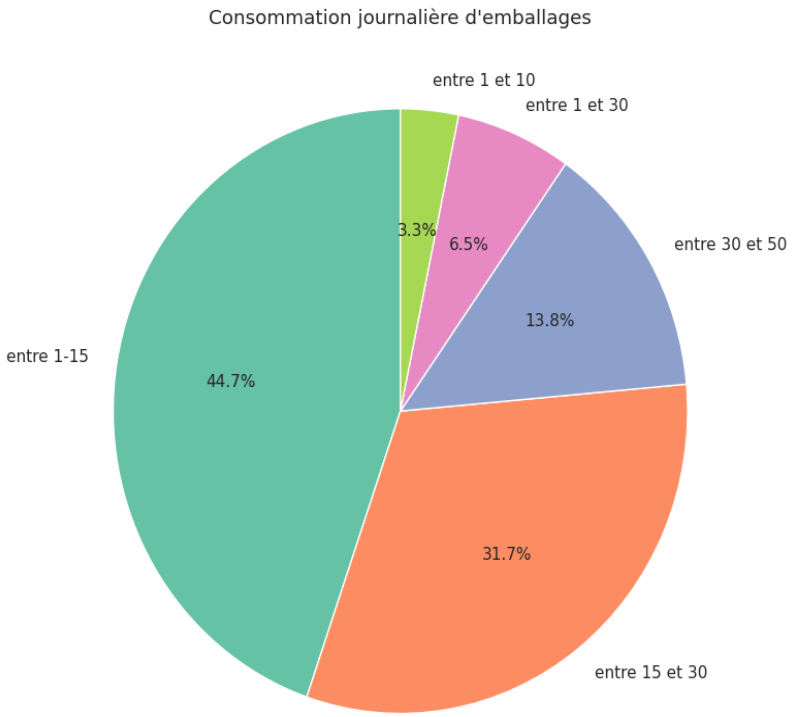

Figure 3 — Quantité d'emballages utilisés par jour par les répondants

Observation : *44,7 % des répondants utilisent entre 1 et 15 emballages par jour, et 31,7 % entre 15 et 30. Ce sont des besoins modérés mais réguliers, typiques de petits restaurateurs qui ont besoin de livraisons fréquentes en quantités raisonnables plutôt que de grosses commandes ponctuelles.*

4.3 Objectifs recherchés avec les emballages

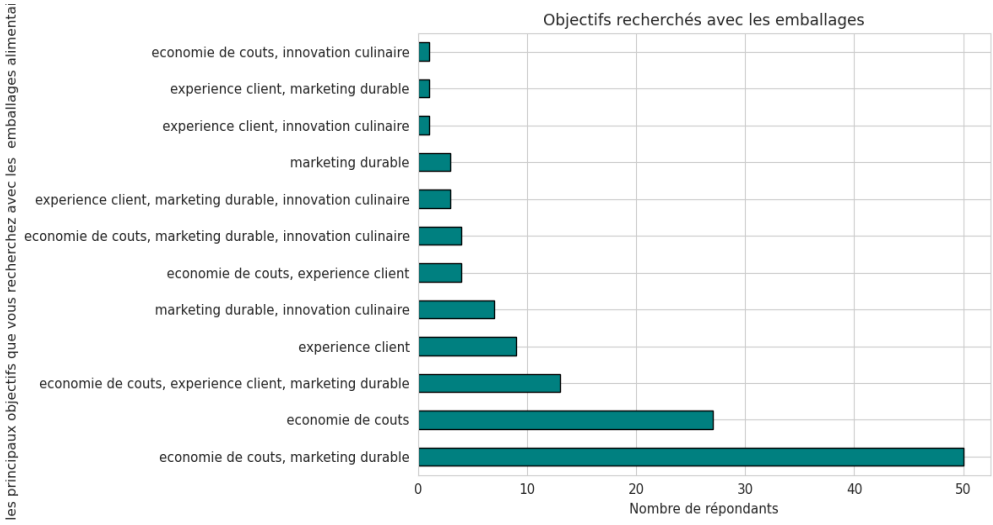

Figure 4 — Objectifs prioritaires recherchés dans les emballages alimentaires

> **Observation :** *L'économie de coûts combinée au marketing durable arrive en tête (40,7 %), suivie par l'économie de coûts seule (22 %). Les clients ne cherchent pas seulement à dépenser moins — ils veulent aussi que l'emballage reflète une image de qualité et de responsabilité environnementale. C'est un signal fort pour le positionnement produit.*

4.4 Préférences produit : taille et compartiments

Deux critères structurent les attentes produit : la taille et le nombre de compartiments.

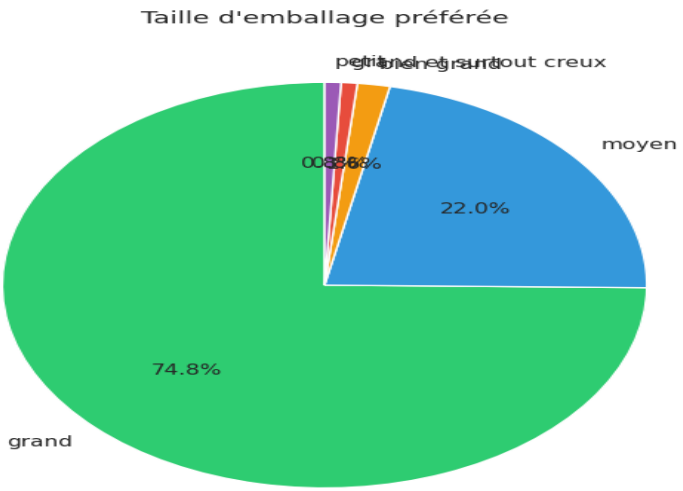

Figure 5 — Préférences de taille d'emballage

La taille grande est de loin la plus demandée (74,8 % des répondants), confirmant que nos clients servent des portions généreuses et ont besoin de contenants spacieux.

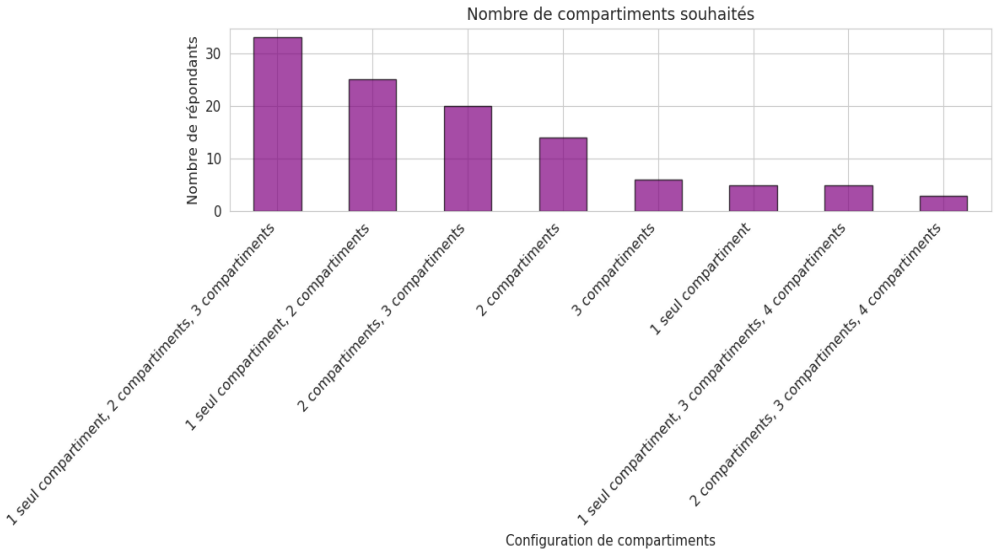

Figure 6 — Préférences en nombre de compartiments

> **Observation :** *La combinaison « 1 seul compartiment + 2 compartiments + 3 compartiments » est la plus populaire (26,8 %), ce qui traduit un besoin de flexibilité plutôt qu'une préférence fixe. En pratique, les clients souhaitent pouvoir choisir selon leurs plats. Proposer les trois formats dès le lancement est donc la stratégie la plus pertinente.*

4.5 Matériaux et caractéristiques préférés

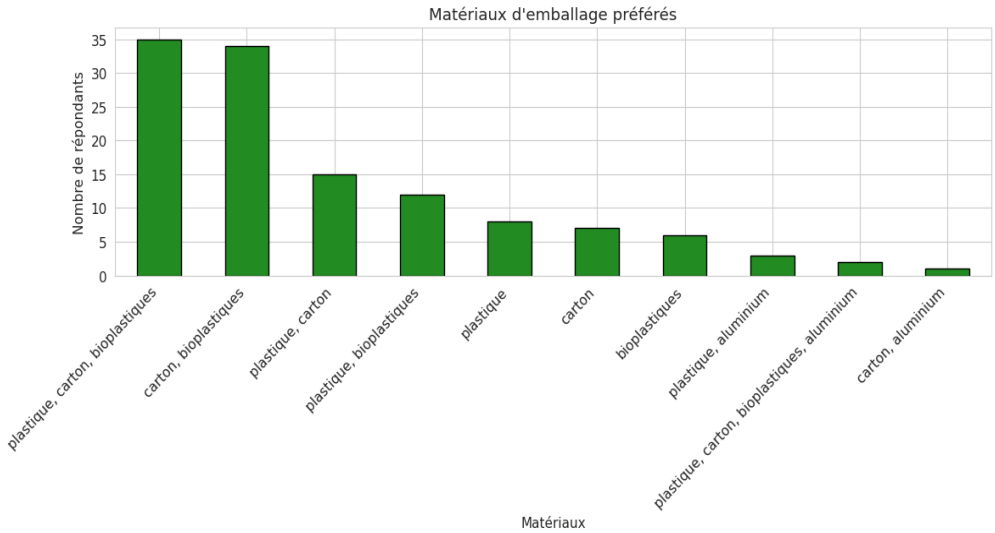

Figure 7 — Matériaux d'emballage privilégiés

Observation : *La combinaison plastique + carton + bioplastiques (28,5 %) domine, suivie de carton + bioplastiques (27,6 %). Les clients veulent de la variété et de l'accessibilité — mais le bioplastique est systématiquement cité, signe d'une conscience environnementale croissante dans ce secteur.*

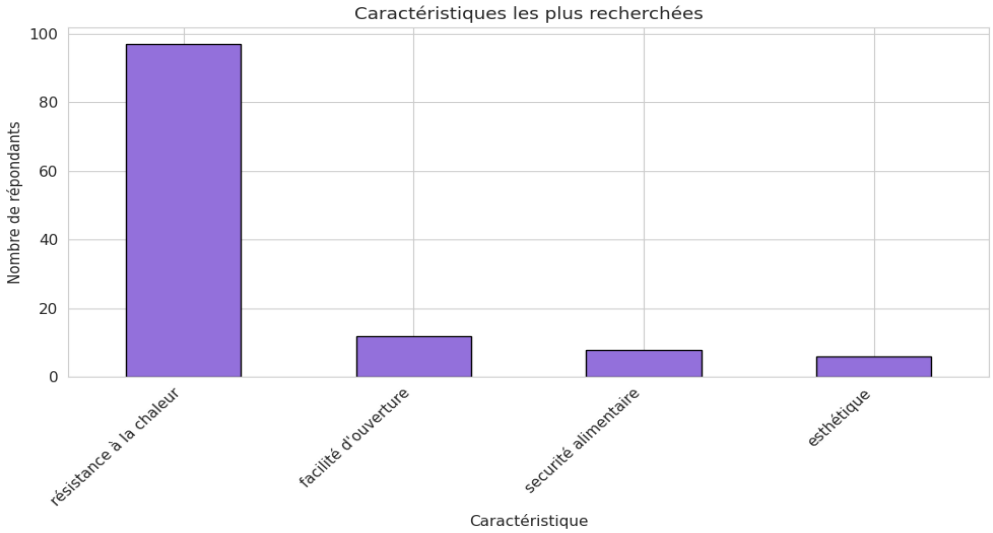

Figure 8 — Caractéristiques fonctionnelles les plus recherchées

Observation : *La résistance à la chaleur est citée par 78,9 % des répondants comme caractéristique prioritaire — un impératif absolu pour des vendeurs de plats chauds. La fenêtre transparente est souhaitée par 78,9 % des répondants également : voir le contenu sans ouvrir l'emballage est perçu comme un atout commercial direct.*

4.6 Sensibilité au prix

Deux indicateurs de prix ont été collectés : la disposition à payer plus que l'offre actuelle, et l'intention d'achat directe.

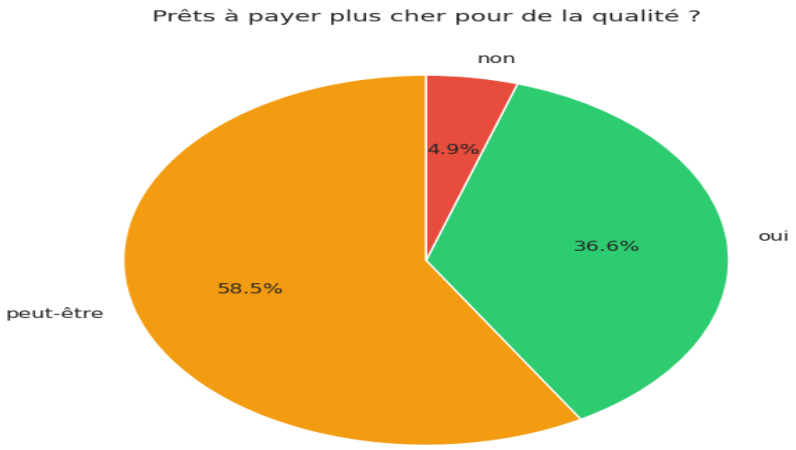

Figure 9 — Disposition à payer légèrement plus cher que l'offre actuelle

> **Observation :** *72 répondants (58,5 %) répondent « peut-être » et 45 (36,6 %) répondent « oui ». Seulement 6 personnes (4,9 %) refusent catégoriquement de payer plus cher. Au total, 95,1 % des clients potentiels sont ouverts à une hausse de prix si le produit justifie sa valeur. C'est un signal très positif pour un positionnement légèrement supérieur au marché actuel.*

4.7 Intention d'achat

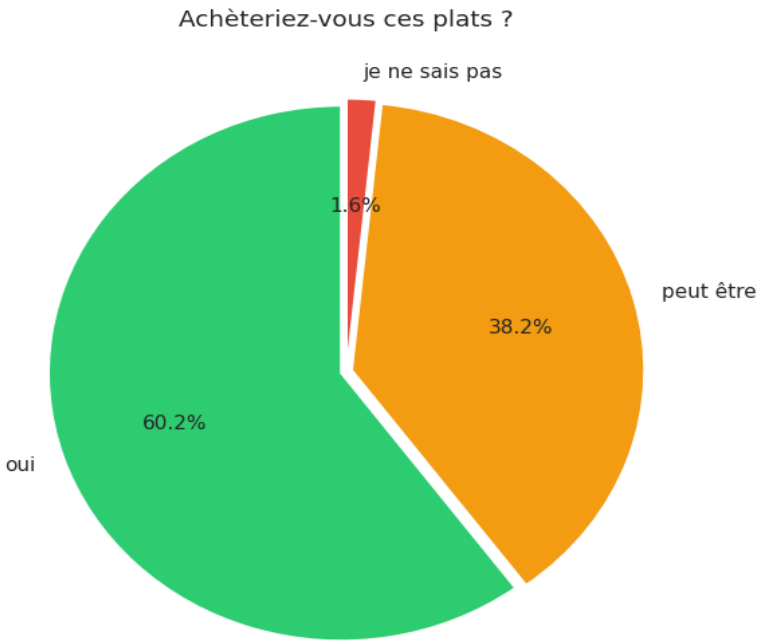

Figure 10 — Intention d'achat exprimée par les répondants

> **Observation :** *74 répondants (60,2 %) déclarent qu'ils achèteraient ces plats, et 47 (38,2 %) répondent « peut-être ». Seuls 2 répondants (1,6 %) sont indécis. En pratique, plus de 98 % des répondants constituent des clients potentiels — un marché extrêmement porteur.*

2.5 Visualisations Avancées

Relation Prix × Intention d'achat

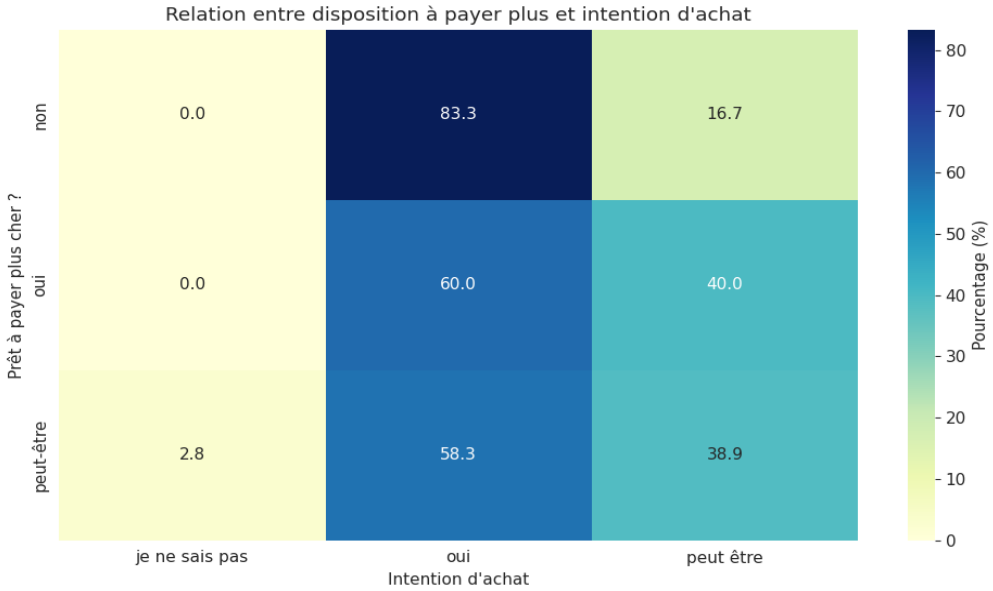

Figure 11 — Heatmap : Relation entre sensibilité au prix et intention d'achat

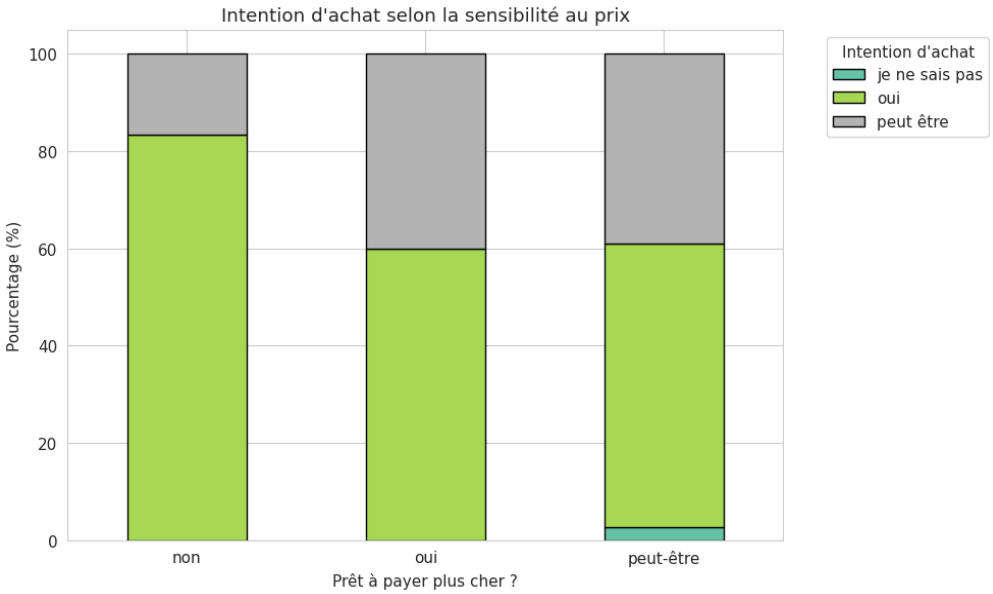

Figure 12 — Intention d'achat selon la sensibilité au prix (barres empilées)

Observation : *Les deux graphiques confirment que même les répondants qui hésitent à payer plus cher maintiennent une forte intention d'achat. La corrélation entre acceptation d'un prix plus élevé et intention d'achat est positive : ceux qui disent « oui » à un prix plus élevé ont aussi l'intention d'achat la plus ferme (60 % de « oui » ferme).*

Préférences d'approvisionnement

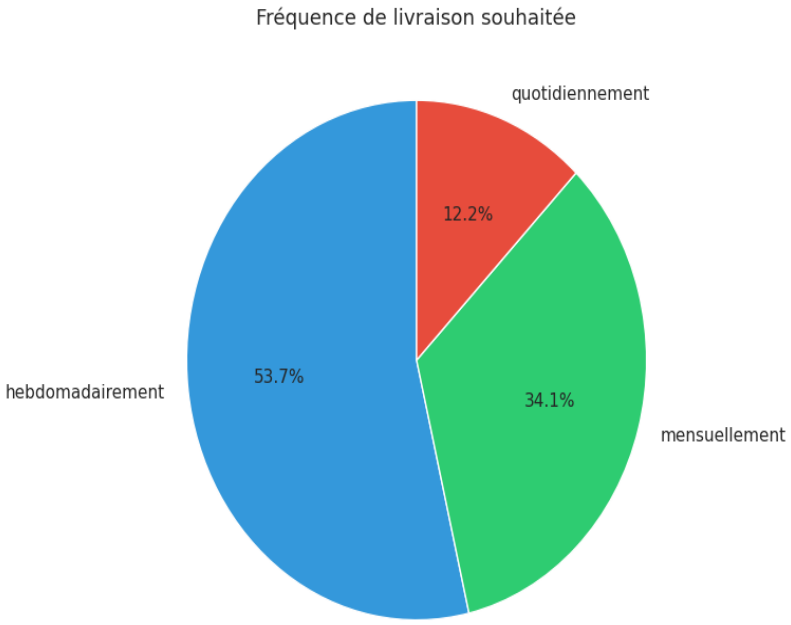

Figure 13 — Fréquence de livraison souhaitée

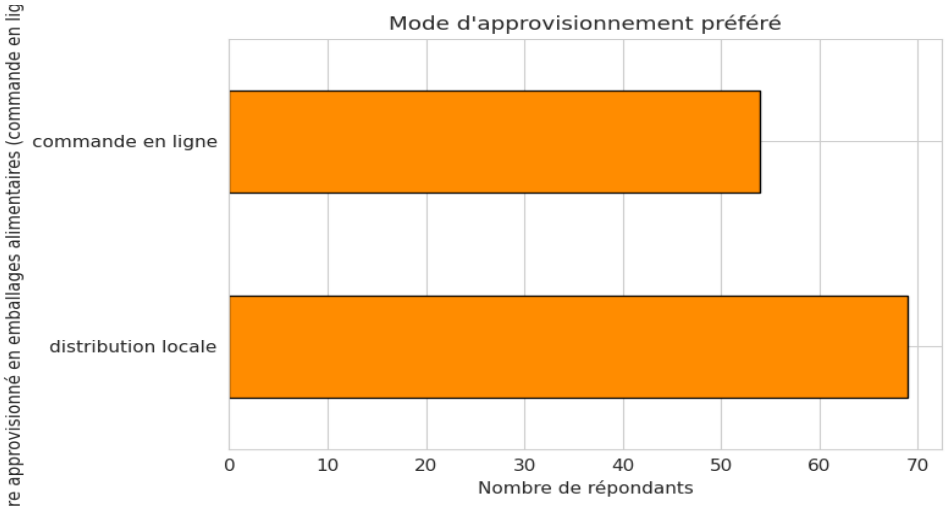

Figure 14 — Mode d'approvisionnement préféré

Fréquence souhaitée	Nb répondants	Part
Hebdomadairement	66	53,7 %
Mensuellement	42	34,1 %
Quotidiennement	15	12,2 %

Tableau 2 — Fréquence de livraison souhaitée

Mode d'approvisionnement	Nb répondants	Part
Distribution locale (livraison directe)	69	56,1 %
Commande en ligne	54	43,9 %

Tableau 3 — Mode d'approvisionnement préféré

> **Observation :** *La livraison hebdomadaire (53,7 %) s'impose comme le rythme de référence. La distribution locale est légèrement préférée à la commande en ligne, mais la dualité des préférences suggère de proposer les deux canaux dès le lancement.*

2.6 Profil Idéal du Produit et Segmentation

Profil du produit idéal

La synthèse des préférences exprimées par les répondants permet de dresser le portrait du produit idéal tel qu'il est attendu par le marché :

Critère	Préférence dominante	Part des répondants
Taille	Grand	74,8 %
Nombre de compartiments	Flexibilité 1+2+3 compartiments	26,8 %
Contenance (1 compartiment)	850 ml	23,6 %
Contenance (2 compartiments)	1 100 ml	35,0 %
Matériaux	Plastique + Carton + Bioplastiques	28,5 %
Fenêtres transparentes	Oui	78,9 %
Caractéristique clé	Résistance à la chaleur	78,9 %
Objectif client	Économie de coûts + Marketing durable	40,7 %

Tableau 4 — Profil du produit idéal issu des préférences des répondants

Segmentation par K-Means

Pour identifier des groupes de clients homogènes, l'algorithme K-Means a été appliqué après encodage des variables catégorielles et standardisation. La méthode du coude a guidé le choix du nombre de clusters.

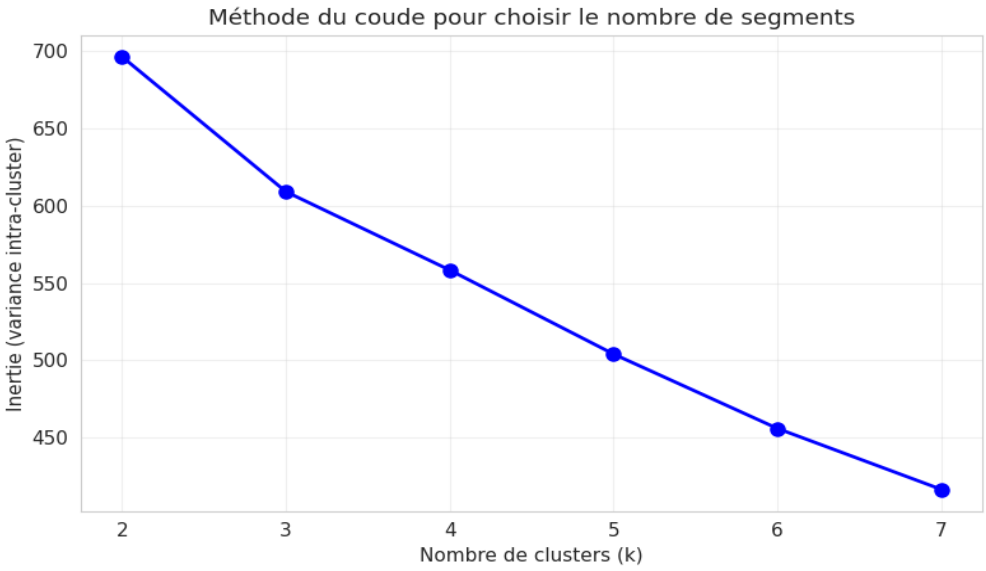

Figure 15 — Méthode du coude : détermination du nombre optimal de clusters

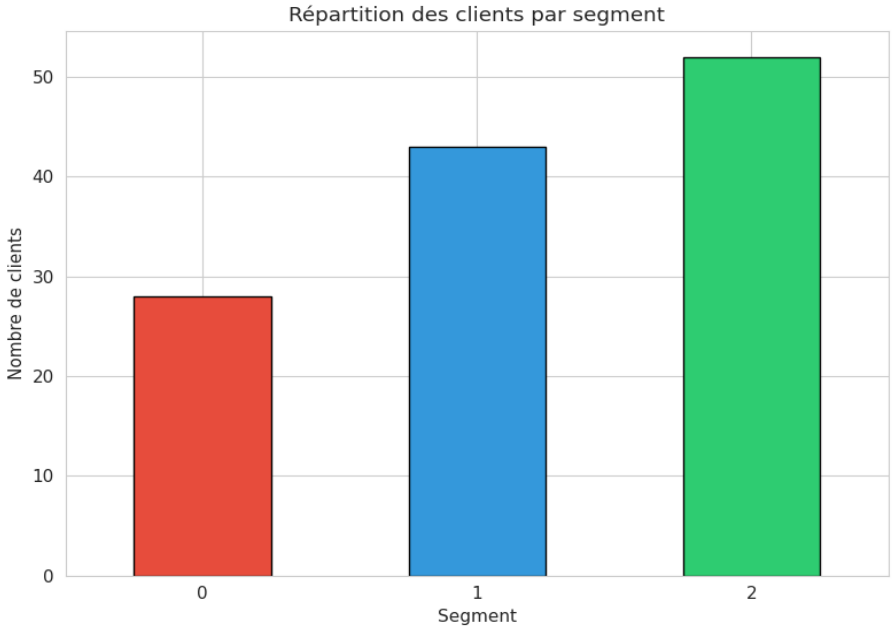

Figure 16 — Répartition des répondants par segment (K-Means, 3 clusters)

Segment	Effectif	Part	Profil caractéristique
Segment 0	28	22,8 %	Clients à besoins limités, budget modéré, volumes faibles
Segment 1	43	34,9 %	Profil intermédiaire — diversité de besoins et flexibilité
Segment 2	52	42,3 %	Clients à fort volume, exigeants sur la qualité et le design

Tableau 5 — Caractéristiques des trois segments identifiés par K-Means

> 💡 **Observation :** *Le Segment 2 est le plus important (42,3 %) et représente le cœur de marché à conquérir : des professionnels à volume élevé qui ont des exigences qualitatives fortes. Ce sont également les clients les plus enclins à payer un prix plus élevé pour un produit qui correspond à leurs attentes.*

2.7 Recommandations Stratégiques

Recommandations produit

Dimension	Recommandation	Justification
Format principal	Lancer en priorité les grands contenants (>700 ml)	74,8 % préfèrent la grande taille
Compartiments	Proposer 1, 2 et 3 compartiments dès le départ	Les clients veulent de la flexibilité
Matériaux	Plastique résistant à la chaleur + option carton/bioplastique	78,9 % exigent résistance à la chaleur
Transparence	Prévoir des fenêtres transparentes en option	78,9 % la souhaitent
Design	Sobre, professionnel, logo possible	Image de marque valorisante pour les clients

Tableau 6 — Recommandations produit

Recommandations prix

Le prix actuel pour 100 plats se situe majoritairement autour de 2 500 FCFA (22 répondants) et 3 500 FCFA (11 répondants). 95,1 % des clients accepteraient de payer légèrement plus si la qualité est au rendez-vous.

Gamme	Prix cible / 100 plats	Cible segment
Entrée de gamme	2 500 – 3 000 FCFA	Segment 0 (22,8 %)
Standard (référence)	3 500 – 4 500 FCFA	Segment 1 (34,9 %)
Premium	5 000 – 7 000 FCFA	Segment 2 (42,3 %)

Tableau 7 — Grille tarifaire recommandée

Recommandations approvisionnement

- Fréquence hebdomadaire : organiser les tournées de livraison chaque semaine pour les clients réguliers (53,7 % le souhaitent).
- Double canal : proposer à la fois la distribution locale directe (56,1 %) et la commande en ligne (43,9 %).
- Stock tampon : maintenir un stock de sécurité correspondant à 2 semaines de ventes pour les formats les plus demandés.
- Anticiper les périodes de forte demande : fêtes, fin d'année, début de saison scolaire.

Projet 2 — Analyse Big Data des Ventes dans le Commerce en Détail

3.1 Contexte et Objectifs

Ce second projet confronte à une réalité techniquement différente : le Big Data au sens strict. Le jeu de données retailsale.csv contient 1 033 434 transactions enregistrées dans un réseau de distribution couvrant 324 produits et 107 magasins, sur la période du 2 janvier au 21 mars 2017. À cette échelle, les outils classiques comme pandas atteignent leurs limites en mémoire et en temps de traitement.

Apache Spark — framework de traitement distribué — a été utilisé pour relever ce défi. Spark permet de fragmenter les calculs sur plusieurs cœurs ou nœuds, de traiter des données en mémoire de façon optimisée, et d'exécuter des transformations complexes sur des millions de lignes en quelques dizaines de secondes.

Les objectifs de ce projet étaient les suivants :

- Charger et prétraiter 1,03 million de lignes dans l'environnement Spark.
- Réaliser une analyse exploratoire approfondie par produit, magasin, promotion et dimension temporelle.
- Visualiser les tendances et mettre en évidence les anomalies.
- Construire et évaluer des modèles prédictifs des ventes.
- Formuler des recommandations concrètes pour améliorer la performance commerciale.

3.2 Description des Données

Le dataset retailsale.csv présente la structure suivante :

Variable	Type	Description
product_id	String	Identifiant du produit (ex : P0001 à P0324)
store_id	String	Identifiant du magasin (ex : S0001 à S0107)
date	Date	Date de la transaction (2017-01-02 à 2017-03-21)
sales	Double	Quantité vendue ce jour pour ce produit/magasin
revenue	Double	Chiffre d'affaires généré (ventes × prix)
stock	Integer	Niveau de stock disponible
price	Double	Prix unitaire du produit

Variable	Type	Description
promo_type_1 / promo_type_2	String	Type de promotion active
promo_bin_1	String	Niveau de promotion (88,47 % de valeurs NULL = pas de promo active)
promo_active	Integer (0/1)	Variable créée : 1 si au moins une promotion active, 0 sinon

Tableau 8 — Structure du jeu de données retailsale.csv

Statistiques globales clés :

Indicateur	Valeur
Nombre de lignes	1 033 434
Nombre de produits	324
Nombre de magasins	107
Période couverte	2 janvier 2017 → 21 mars 2017
Total des ventes (unités)	612 642
Total des revenus	1 968 846,77 €
Prix moyen	9,25 €
Ventes moyennes par ligne	0,59 unité/jour

Tableau 9 — Statistiques globales du dataset

3.3 Prétraitement avec Spark

La configuration de la session Spark a été la première étape, avec allocation de 4 Go de mémoire pour le driver :

```
spark = SparkSession.builder.appName('Retail Analysis').config('spark.driver.memory','4g').getOrCreate()
```

Valeurs manquantes

La vérification des valeurs manquantes a révélé une situation particulière : seule la colonne promo_bin_1 présente des valeurs NULL (914 269 lignes, soit 88,47 %). Ce n'est pas une erreur de collecte : ces NULL signifient simplement qu'aucune promotion de ce type n'était active pour ces lignes. Toutes les autres colonnes sont complètes.

Colonne	Valeurs NULL	Interprétation
promo_bin_1	914 269 (88,47 %)	Pas de promotion de niveau 1 active — comportement normal
Toutes les autres colonnes	0 (0 %)	Données complètes et cohérentes

Tableau 10 — Valeurs manquantes après inspection

Vérification des anomalies

Une vérification systématique des valeurs aberrantes confirme la qualité du dataset :

Type d'anomalie recherchée	Résultat
Ventes négatives	0 cas détecté
Prix nuls ou négatifs	0 cas détecté
Stock négatif	0 cas détecté
Revenus négatifs	0 cas détecté

Tableau 11 — Résultat de la vérification des anomalies

Variables créées

Pour enrichir l'analyse, les variables suivantes ont été construites à partir des données existantes :

- year, month, day_of_week, week_of_year : décomposition temporelle de la colonne date.
- revenue_calc = sales × price : vérification du calcul de revenus (cohérence avec la colonne revenue).
- promo_active = 1 si au moins une promotion est active (promo_type_1 ou promo_type_2 non null), 0 sinon.
- rupture_stock = 1 si stock = 0, pour identifier les situations de rupture.

3.4 Analyse Exploratoire et Analytique

Performances par produit et par magasin

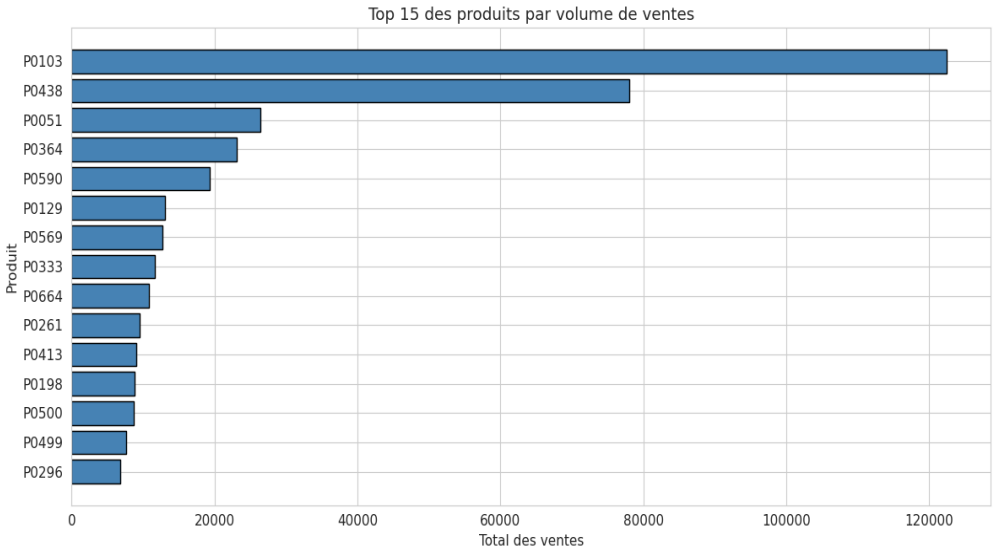

Figure 17 — Top 15 produits par volume de ventes

Rang	Produit	Total ventes (unités)	Revenu total (€)	Prix moyen (€)
1	P0103	122 472	254 597,94	2,66
2	P0438	78 075	17 702,33	0,25
3	P0051	26 381	16 782,56	0,70
4	P0364	23 065	20 596,95	1,00
5	P0590	19 334	8 694,91	0,49

Tableau 12 — Top 5 produits par volume de ventes

💡 **Observation :** *P0103 domine très largement avec 122 472 unités vendues et un revenu de 254 597 €. Il s'agit probablement d'un produit de grande consommation à prix bas mais à fort volume. P0438 est vendu en quantité importante (78 075 unités) mais génère peu de revenus (0,25 € l'unité) — c'est un produit d'appel ou de forte rotation à très faible marge.*

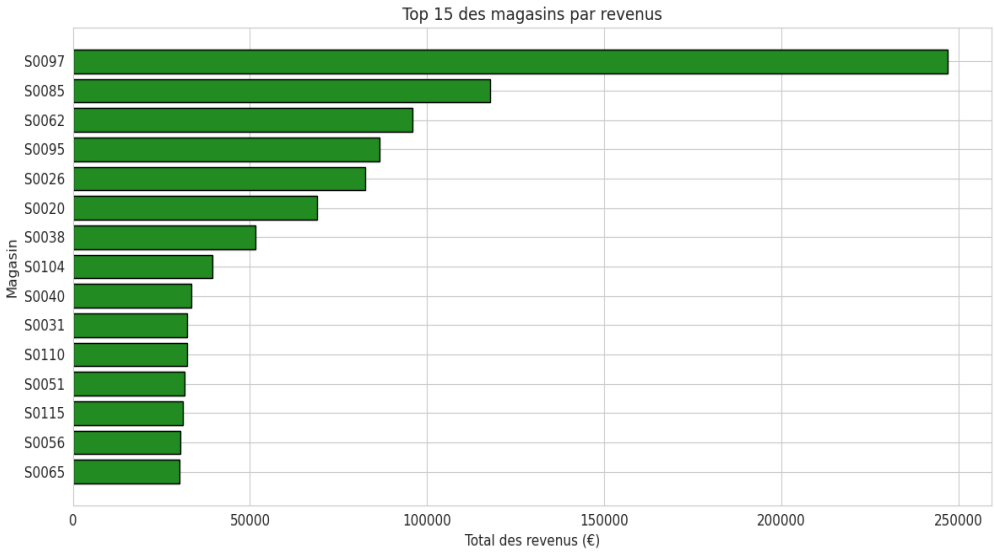

Figure 18 — Top 15 magasins par revenus totaux

Rang	Magasin	Ventes totales	Revenus totaux (€)	Nb transactions
1	S0097	98 847	247 042,62	17 406
2	S0085	37 937	117 882,50	19 140
3	S0062	18 317	95 943,76	16 590
4	S0095	13 798	86 527,66	11 292
5	S0026	19 473	82 572,55	16 661

Tableau 13 — Top 5 magasins par revenus

💡 **Observation :** *S0097 génère le revenu le plus élevé (247 042 €) avec seulement 17 406 transactions, ce qui indique un panier moyen élevé. S0085 fait davantage de transactions (19 140) pour un revenu inférieur — signe d'un magasin axé sur le volume plutôt que la valeur. Cette différence de profil justifie des stratégies commerciales distinctes pour chaque magasin.*

Évolution temporelle des ventes et revenus

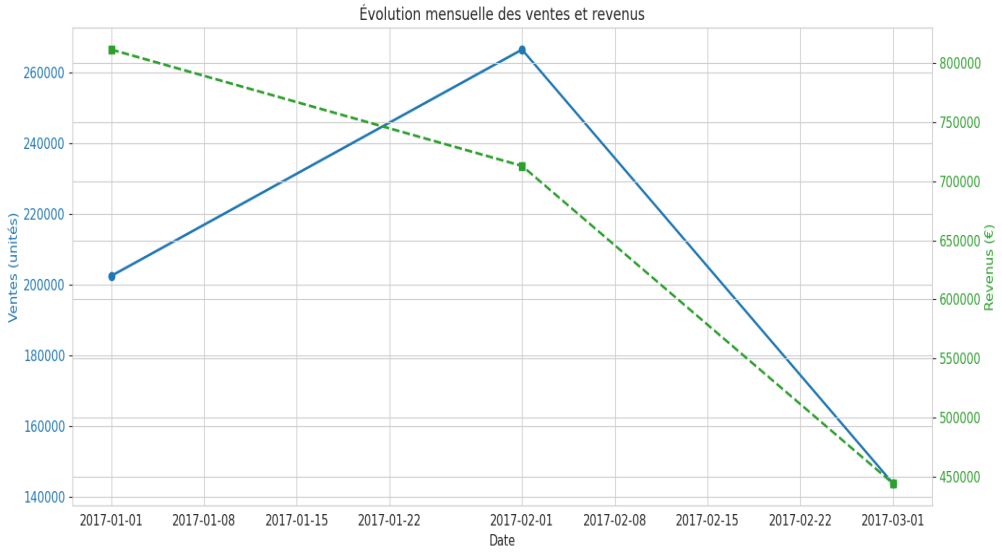

Figure 19 — Évolution mensuelle des ventes et des revenus (janvier–mars 2017)

Mois	Total ventes (unités)	Total revenus (€)
Janvier 2017	202 464	811 569,43
Février 2017	266 362	713 090,28
Mars 2017 (partiel)	143 815	444 187,06

Tableau 14 — Ventes et revenus mensuels

> **Observation :** *Février 2017 affiche le volume de ventes le plus élevé (266 362 unités), mais janvier génère le revenu le plus important (811 569 €). Cette contradiction apparente s'explique par la composition du mix produits : en janvier, des produits à prix plus élevé ont été davantage vendus. Les données de mars sont partielles (jusqu'au 21 mars seulement).*

Impact des promotions

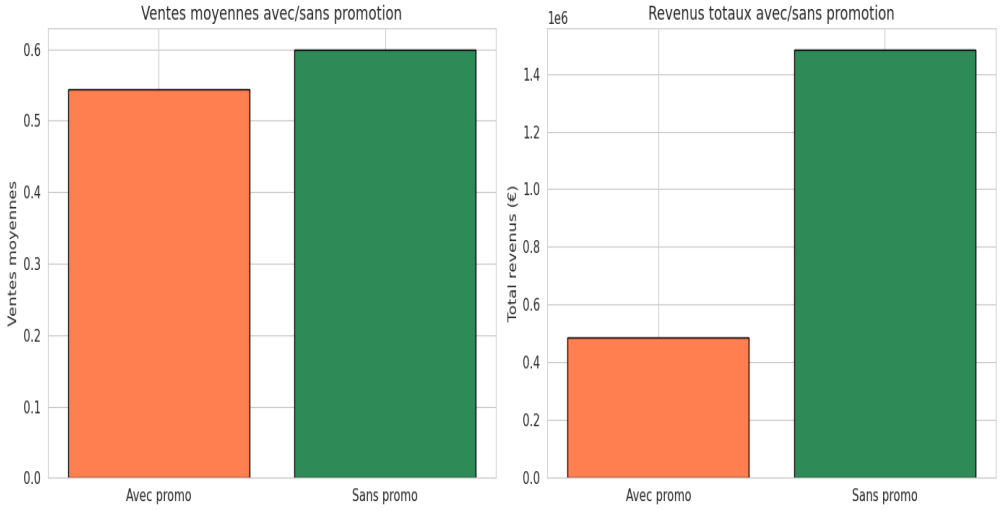

Figure 20 — Comparaison des ventes moyennes avec et sans promotion

Condition	Nb de lignes	Ventes moyennes	Total ventes (unités)	Total revenus (€)
Sans promotion	914 269	0,599	547 742	1 482 423,33
Avec promotion	119 165	0,545	64 901	486 423,44

Tableau 15 — Impact des promotions sur les performances de ventes

Observation : *Résultat contre-intuitif : les lignes avec promotion affichent des ventes moyennes légèrement inférieures (0,545 vs 0,599). Ce phénomène peut s'expliquer par le fait que les promotions sont concentrées sur les produits à faible rotation, ou que les clients achètent moins de quantité quand le prix unitaire est réduit. La corrélation promo-ventes mesurée est de −0,0004, quasi-nulle. La stratégie promotionnelle mérite une révision profonde.*

Relation prix et volume des ventes

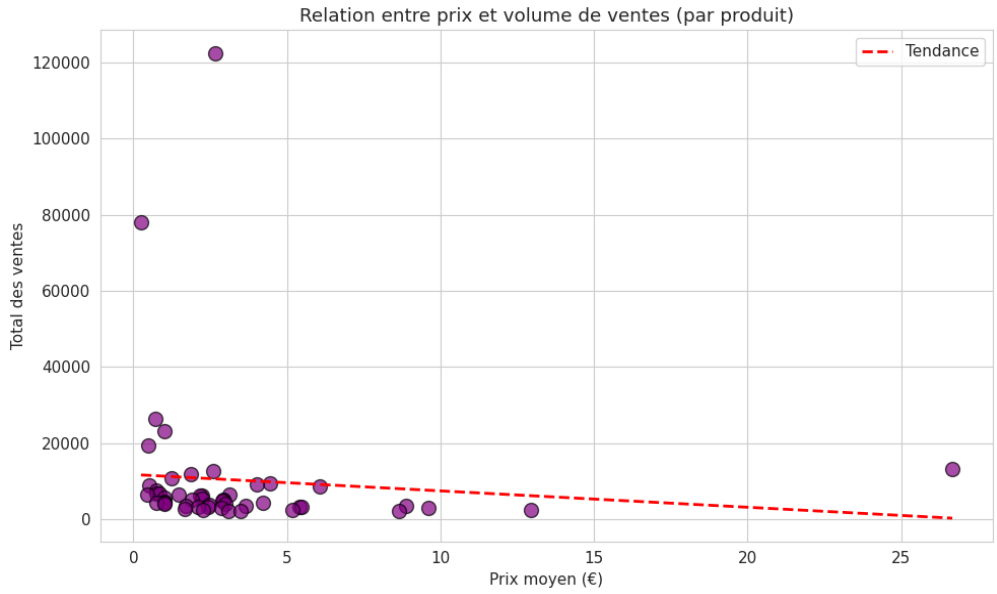

Figure 21 — Relation entre prix moyen et volume de ventes par produit

> **Observation :** *Le nuage de points confirme la corrélation négative entre prix et ventes ($r = -0{,}0065$) : globalement, les produits les moins chers se vendent en plus grand volume. Toutefois, la corrélation est très faible, signe que d'autres facteurs (notoriété du produit, saison, disponibilité en stock) jouent un rôle tout aussi important.*

Tendance cumulée des revenus

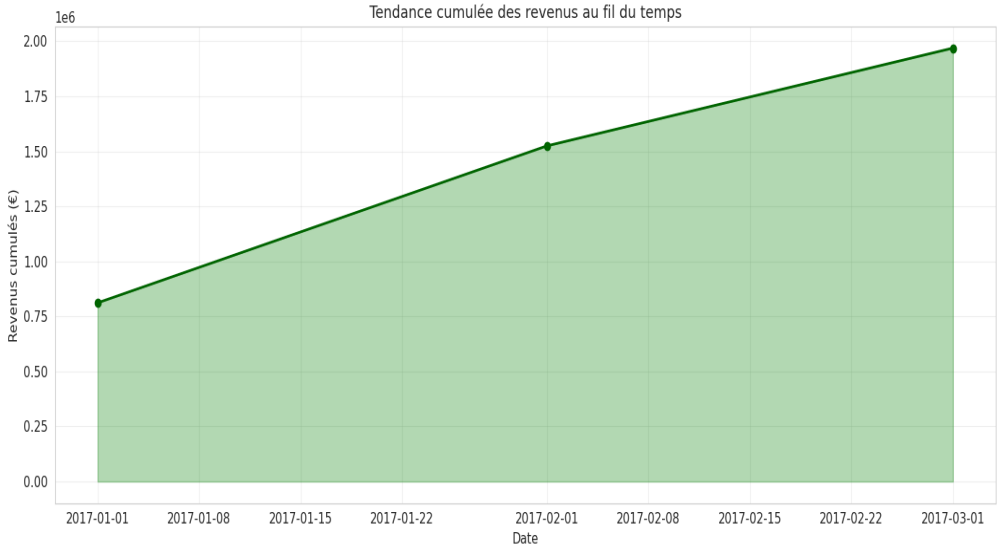

Figure 22 — Revenus cumulés au fil du temps (tendance linéaire ascendante)

> **Observation :** *La courbe des revenus cumulés est linéaire et régulière, sans rupture notable sur la période analysée. Cette progression constante indique une activité stable, sans*

saisonnalité marquée sur les 80 jours couverts. Une analyse sur une période plus longue serait nécessaire pour détecter d'éventuels effets saisonniers.

Corrélations entre variables

Pair de variables	Coefficient de corrélation	Interprétation
Prix vs Ventes	−0,0065	Légère corrélation négative — produits moins chers = plus de ventes
Stock vs Ventes	+0,0285	Très faible corrélation positive — stock disponible facilite légèrement les ventes
Promo vs Ventes	−0,0004	Corrélation quasi nulle — promotions sans effet mesurable sur les ventes
Prix vs Revenus	+0,0084	Très faible corrélation — revenus peu liés au prix unitaire seul

Tableau 16 — Matrice des corrélations entre les principales variables

Observation : *Les corrélations sont toutes très faibles (< 0,03 en valeur absolue), ce qui indique que les ventes dépendent de multiples facteurs non capturés dans ce dataset (météo, événements locaux, concurrence, comportement du consommateur). C'est une limite importante pour la modélisation.*

3.5 Modélisation Prédictive

Objectif et features utilisées

L'objectif est de prédire le volume de ventes (variable cible : sales) à partir des variables disponibles. Cinq features ont été sélectionnées :

Variable explicative	Importance attendue
price	Prix unitaire du produit
stock	Niveau de stock disponible
promo_active	Présence ou non d'une promotion
month	Mois de la transaction (saisonnalité)

Variable explicative	Importance attendue
day_of_week	Jour de la semaine (effets de cycle hebdomadaire)

Tableau 17 — Features utilisées pour la modélisation

Le dataset a été divisé en ensemble d'entraînement (80 %, soit 826 732 lignes) et ensemble de test (20 %, soit 206 702 lignes).

Modèle 1 — Régression Linéaire

La régression linéaire est le modèle de base, interprétable et rapide. Les coefficients estimés sont les suivants :

Variable	Coefficient	Interprétation
price	−0,0136	Chaque euro supplémentaire de prix réduit légèrement les ventes
stock	+0,0289	Un stock plus élevé facilite très légèrement les ventes
promo_active	−0,0509	La promotion est associée à de légèrement moins de ventes
month	+0,0230	Légère progression des ventes au fil des mois
day_of_week	+0,0113	Effet jour de semaine modeste
Intercept	0,1814	Valeur de base des ventes en l'absence de toute variable

Tableau 18 — Coefficients de la régression linéaire

Modèle 2 — Random Forest

Le Random Forest est un algorithme d'ensemble plus puissant en théorie, mais qui requiert un réglage soigneux des hyperparamètres.

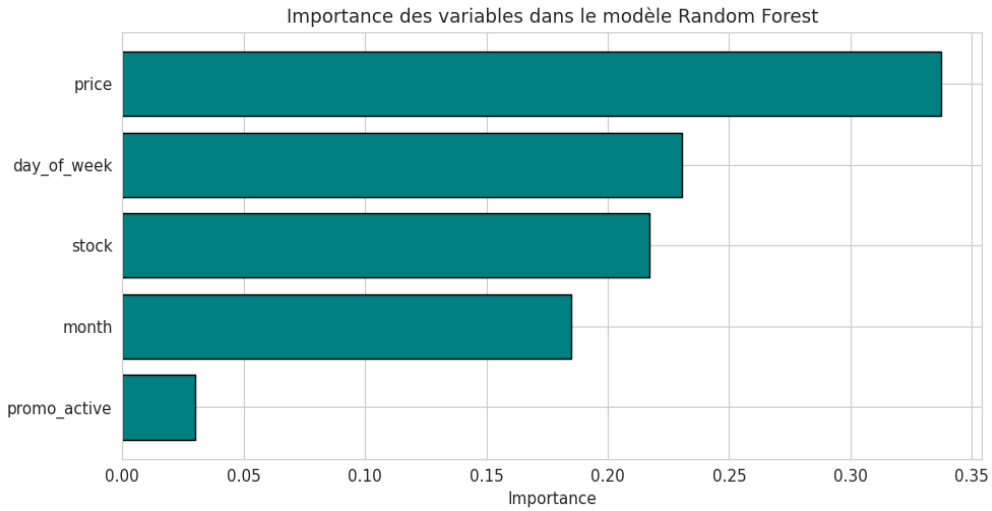

Figure 23 — Importance des features selon le modèle Random Forest

Comparaison des performances

Modèle	RMSE	MAE	R^2	Verdict
Régression Linéaire	2,5019	0,7926	0,1733	Meilleur modèle ✓
Random Forest (défaut)	4,1747	0,7622	−1,3017	Sous-performant ✗

Tableau 19 — Comparaison des performances des deux modèles

Variable	Importance (Random Forest)
price	33,72 % — facteur le plus déterminant
day_of_week	23,07 % — effets de jour de semaine importants
stock	21,71 % — impact du niveau de stock
month	18,48 % — effet saisonnier
promo_active	3,01 % — impact très faible des promotions

Tableau 20 — Importance des variables selon le Random Forest

Observation : *La Régression Linéaire (R^2=0,173) est significativement meilleure que le Random Forest (R^2=−1,30). Un R^2 négatif signifie que le Random Forest prédit moins bien qu'une simple moyenne — symptôme d'un sur-ajustement avec les hyperparamètres par*

défaut. Le prix est la variable la plus influente dans les deux modèles, suivi du jour de la semaine et du niveau de stock.

3.6 Recommandations Stratégiques et Opérationnelles

1. Repenser la stratégie promotionnelle

Le constat le plus frappant de cette analyse est que les promotions n'améliorent pas les ventes moyennes. Avant de continuer à investir dans des remises, il est indispensable de comprendre pourquoi. Les pistes à explorer sont : les promotions ciblent-elles les bons produits ? Les clients ont-ils réellement modifié leur comportement d'achat en réponse à ces promotions ? Une expérimentation contrôlée avec des groupes de magasins test et témoin permettrait de répondre à ces questions. Les mécanismes alternatifs à tester incluent les promotions en bundle, les programmes de fidélité et les offres sur les produits à fort potentiel de croissance.

2. Optimiser la stratégie de prix

Le prix est le levier le plus puissant identifié dans les deux modèles (34 % d'importance). Une analyse de l'élasticité prix catégorie par catégorie permettrait d'identifier où des ajustements tarifaires seraient les plus rentables. La mise en place d'un pricing dynamique — où les prix s'ajustent selon la demande, les niveaux de stock et les comportements concurrentiels — est une piste sérieuse pour les magasins à fort volume comme S0097.

3. Sécuriser la gestion des stocks

Le stock est le deuxième facteur d'importance (21,71 %). Les ruptures de stock constituent donc une perte directe de revenus. Une amélioration de la planification des réassorts, s'appuyant sur des modèles de prévision de la demande par produit et par magasin, permettrait de réduire significativement ces ruptures. Le jeu de données contient l'information de rupture (stock = 0) qui peut servir de base à cet exercice.

4. Améliorer les modèles prédictifs

Le R^2 de 0,173 indique qu'une grande partie de la variance des ventes reste inexpliquée. Pour améliorer la qualité prédictive, il convient d'enrichir le jeu de données avec des variables contextuelles (météo, jours fériés, événements locaux, densité concurrentielle), d'explorer des algorithmes plus puissants (XGBoost, LightGBM, réseaux de neurones) et de réaliser un tuning sérieux des hyperparamètres du Random Forest (nombre d'arbres, profondeur maximale, taux d'échantillonnage).

Conclusion Générale

Ces deux projets ont constitué une immersion concrète dans deux réalités différentes de la Data Science, complémentaires dans leur approche et leurs enseignements.

Le premier projet — l'analyse de l'enquête de marché — rappelle que la donnée la plus précieuse n'est pas toujours la plus volumineuse. 123 réponses bien collectées et bien analysées suffisent à construire une vision claire du marché : un taux d'utilisation de 100 % des emballages jetables chez les répondants, une demande forte pour les grands formats résistants à la chaleur, un prix accepté autour de 3 500 à 4 500 FCFA pour 100 plats, et une segmentation en trois profils distincts qui orientent directement la stratégie de gamme. Le taux d'intention d'achat de 98,4 % confirme l'existence d'un marché porteur.

Le second projet — l'analyse Big Data avec Apache Spark — démontre que la même rigueur analytique s'applique à une échelle radicalement différente. Plus d'un million de transactions traitées, 107 magasins et 324 produits analysés, deux modèles prédictifs construits et évalués. L'enseignement le plus important reste la découverte contre-intuitive : les promotions n'améliorent pas les ventes moyennes dans ce réseau. Ce résultat, s'il était confirmé sur une période plus longue, devrait conduire à une refonte complète de la stratégie promotionnelle. Le modèle de régression linéaire (R^2=0,173), modeste mais honnête, pose les bases d'une prédiction des ventes que des données plus riches permettraient d'améliorer.

Sur le plan technique, ce projet illustre parfaitement pourquoi Spark s'impose dans les architectures Big Data modernes : là où pandas nécessiterait de charger l'intégralité du fichier en mémoire RAM, Spark distribue le calcul et maintient des temps de réponse raisonnables. Cette différence n'est pas anecdotique — elle conditionne la faisabilité même de l'analyse à grande échelle.

En définitive, ces deux projets illustrent que la valeur de la Data Science ne réside pas dans la complexité des algorithmes utilisés, mais dans la qualité des questions posées, la rigueur du traitement des données, et la capacité à traduire les résultats en recommandations utiles pour les décideurs.

Annexes

Annexe A — Lien vers le code source

Conformément aux consignes, les notebooks Jupyter ayant servi à l'analyse sont disponibles à l'adresse suivante :

https://github.com/Anjorin007/Projet_Big_data

- projet1_enquete_marche.ipynb — Analyse de l'enquête de marché (pandas, scikit-learn)
- projet2_spark_retail.ipynb — Analyse Big Data avec Apache Spark

Annexe B — Environnement technique

Projet	Bibliothèque / Framework	Usage
Projet 1	pandas 2.x	Chargement, nettoyage et analyse des données
Projet 1	numpy	Calculs numériques
Projet 1	matplotlib / seaborn	Visualisations
Projet 1	scikit-learn (KMeans)	Segmentation clients
Projet 2	Apache Spark (PySpark 4.0.1)	Traitement distribué Big Data
Projet 2	pandas	Post-traitement et conversion pour visualisation
Projet 2	matplotlib / seaborn	Visualisations
Projet 2	Spark MLlib (LinearRegression, RandomForestRegressor)	Modélisation prédictive

Tableau 21 — Environnement technique et bibliothèques

Annexe C — Structure des fichiers

```
Projet_Big_data/
├── enquête.xlsx                    # Données enquête (Projet 1)
├── retailsale.csv                  # Données retail Big Data (Projet 2)
├── projet1_enquete_marche.ipynb    # Notebook complet Projet 1
├── projet2_spark_retail.ipynb      # Notebook complet Projet 2
└── Rapport_Infrastructure_Big_Data_PIGIER.pdf  # Ce rapport
```